

基于 K-means 聚类 and 特征提取的手写数字识别

孟灏 张宗利

2026 年 1 月 14 日

目录

1	引言	1
1.1	问题背景与研究目标	1
1.2	国内外相关研究现状	2
2	理论基础	3
2.1	无监督学习	3
2.2	聚类	3
2.3	相似度度量	4
2.4	K-means 聚类	4
2.5	聚类数 K	6
2.6	K-medoids 聚类	7
3	技术细节	8
3.1	聚类标签的对齐	8
3.2	图像旋转	9
3.3	HOG	10
4	实验结果	11
4.1	直接采用 K-means 聚类	11
4.2	引入 PCA 旋转方法	13
4.3	提取 HOG 特征	13
4.4	增加聚类数 K	15

5 总结	17
6 参考文献	17

1 引言

1.1 问题背景与研究目标

随着大数据时代的到来，获取海量原始数据的成本逐渐降低，但人工标注数据的过程依然昂贵且耗时。因此，无监督学习（Unsupervised Learning）成为了机器学习研究的前沿阵地。聚类（Clustering）分析作为其核心分支，能够在无需先验标签的情况下，通过挖掘数据内在的统计特性实现自动分类。在图像处理和数据挖掘等领域，聚类算法是理解复杂数据结构的关键工具。

在众多的聚类算法中，K-means 算法凭借其数学模型直观、计算复杂度低（线性于样本数）以及良好的收敛性，成为了应用广泛的基准算法之一。在处理具有球形分布特征的数据集时，K-means 展现出了极高的效率。对于研究者而言，深入探讨 K-means 的实现机制及其在特定任务中的表现，是理解聚类理论的最佳切入点。

手写数字识别（Handwritten Digit Recognition）是计算机视觉领域的经典课题。MNIST 数据集（Modified National Institute of Standards and Technology database）由美国国家标准与技术研究院（NIST）的两个数据集修改而来，最早由著名学者 Yann LeCun 等人推广使用。由于其简洁性和标准化，它成为了手写数字识别领域的基准数据集。MNIST 包含 70000 张手写数字（0 到 9，共十个阿拉伯数字）图片，它们都经过了预处理和尺寸归一化，每张图片都被量化为 28×28 像素的灰度（值为 0 到 255）矩阵，包含丰富的人类书写风格差异。

尽管以卷积神经网络（CNN）为代表的深度学习方法已在该数据集的分类（Classification）问题上取得了接近人类水平的准确率，但这些方法高度依赖于大规模的有监督标注。实际上，在本项目中，我们更关心的是无监督场景下 MNIST 数据集的手写数字聚类问题。具体来说，对于 MNIST 数据集，我们希望以 K-means 算法为基础，探索如何在缺乏先验标签引导的前提下，仅通过数据自身的分布规律，实现对数字类别的精准划分。理想结果下，我们可以利用上述划分实现半自动化的数据标注，在一定程度上降低人工标注数据的成本。

1.2 国内外相关研究现状

关于手写数字识别及高维图像数据的聚类问题，国内外学者在过去几十年中进行了广泛的探索，研究重点主要集中在提高算法的计算效率、处理非球形分布以及挖掘数据的局部空间结构等方面。

首先，为解决传统 K-means 算法在处理非线性分布数据时的局限性，Zhang 和 Rudnicky (2002) 提出了一种基于核 K-means (Kernel K-means) 的大规模聚类方案 [1]。该研究通过引入核函数将原始数据映射到高维特征空间，使得在低维空间中线性不可分的数据变得线性可分，并有效解决了核矩阵计算开销巨大的问题，为 MNIST 等大规模数据集的非线性聚类提供了理论支撑。

在挖掘数据内在几何结构方面，Liu 等人 (2010) 提出了具有局部一致性的高斯混合模型 (Gaussian Mixture Model with Local Consistency) [2]。该研究指出，像 MNIST 这样的图像数据通常嵌入在高维空间的低维流形上，通过在概率生成模型中引入图正则化约束，可以使聚类结果在保持全局统计特性的同时，兼顾数据的局部几何结构，显著提升了无监督识别的准确性。

国内学者在聚类算法的初始化与鲁棒性方面也取得了显著成果。例如，陈新庚等 (2003) 探讨了 K-means 算法对初始聚类中心的依赖问题，提出了基于密度权重的改进策略，有效避免了算法陷入局部最优解。此外，针对图像特征的复杂性，研究者开始将主成分分析 (PCA) 与线性判别分析 (LDA) 等降维技术与 K-means 结合，以剔除原始像素中的冗余噪声。[3]

近年来，随着深度学习的兴起，深度聚类 (Deep Clustering) 成为了新的研究热点。Xie 等人 (2016) 提出了深度嵌入聚类 (DEC)，利用自编码器 (Autoencoder) 学习适合聚类的特征表示，并定义了一个基于 KL 散度的聚类目标函数进行联合优化 [4]。随后，Ji 等人 (2019) 进一步提出了不变信息聚类 (IIC)，通过最大化图像及其变换版本之间的互信息，实现了在完全无监督条件下对 MNIST 数据集的高精度划分 [5]。

综上所述，虽然以 K-means 为代表的传统聚类算法在直接处理原始图像时面临挑战，但通过结合特征提取、核方法等技术，其在无监督场景下的表现仍具备极强的研究价值与实践意义。

2 理论基础

2.1 无监督学习

在机器学习的领域，无监督学习旨在从未标注的数据中揭示数据的内在结构与规律。与有监督学习不同，无监督学习并不依赖于人工标注或期望输出，仅通过分析数据样例 $x_1, x_2, \dots, x_N$ 本身进行学习。从概率分布的角度来看，有监督学习主要关注条件分布 $P(Y|X)$ ，即在给定输入特征的情况下预测类别；而半监督学习则尝试结合少量有标注数据与大量无标注数据来学习 $P(Y|X)$ ；相比之下，无监督学习的核心目标则是直接拟合数据的联合分布 $P(X)$ ，从而在无外部指导的情况下探索数据的本质特征。

进一步深入探讨，无监督学习的核心目标在于构建有效的模型以提取输入数据的有用表示。这些表示不仅能够用于对未来输入进行预测，还可作为特征输入传递给其他学习器，以支持后续的机器学习任务。在此过程中，算法的关键能力在于能够从数据中识别出潜在的模式与结构，从而将数据中蕴含的有意义信息与非结构化的噪音区分开来。这种对数据内在结构的发现能力，是无监督学习在处理高维、复杂数据时的重要价值所在 [6]。

2.2 聚类

聚类作为无监督学习中最具代表性的任务之一，其本质是将相似的对象归入同一个“类”或簇中。具体而言，聚类算法旨在通过最大化同一类别内部对象之间的相似性（即类内相似度），同时最小化不同类别之间对象的相似性（即类间相似度），从而实现数据的有效分组。在此过程中，如何定义并量化“相似度”构成了聚类的核心问题，这直接关系到算法对数据结构的捕捉能力。评价聚类结果优劣的关键标准在于其“紧凑性”与“分离性”：一个好的聚类结果应当具有较小的类内距离，意味着簇内样本紧密聚集；同时具备较大的类间距离，意味着不同簇之间存在明显的界限与差异。

在聚类的具体实现中，可以根据划分的严格程度将其分为软聚类和硬聚类。硬聚类规定每个对象只能唯一归属于某一个类别，划分边界清晰；而软聚类则允许同一个对象以不同的隶属度同时属于多个类别，这种模糊性在某些复杂场景下更能反映数据的真实分布。此外，依据聚类结果的结构形式，还可以将其区分为层次聚类与非层次聚类。层次聚类构建的是一个涵盖所有类别间关系的树状层次结构，能够直观展示数据在不同粒度下的聚集情况；相比之下，非层次聚类生成的则是扁平化的划分结果，仅包含单层的

类别信息 [7]。

2.3 相似度度量

为了准确衡量对象间的相似程度，选择合适的度量方法至关重要，这通常取决于数据的具体类型。

对于非数值数据，若数据为二值属性，通常采用简单的匹配规则：即当两个对象属性值相等时，相似度定义为 1，否则为 0。对于更复杂的非数值对象，可以利用其语义属性来计算相似度，例如基于地理距离的反比关系。

$$Sim(Boston, LA) = \alpha \cdot dist(Boston, LA)^{-1}$$

此外，还可直接使用相似度矩阵来表示对象间的关联，该矩阵通常满足对角线为 1.0 的归一化条件。值得注意的是，这种方法无需依赖线性假设，但为了确保聚类的有效性，相似度矩阵需要满足传递性这一核心要求，即传递性被视为聚类过程中的重要目标。

对于有序值数据，通常的处理策略是将其归一化映射至 $[0, 1]$ 区间内的实数值。具体操作时，将属性中的最大值设为 1，最小值设为 0，其余数值通过插值计算转换，从而可以直接套用前述实数值变量的相似度度量方法。当然，有序值数据也可以选择构建相似度矩阵来进行描述。

针对实数值数据，相似度的度量方式更为丰富多样。常用的方法包括内积、余弦相似度以及基于核函数的度量等。此外，Minkowski 距离也是一类重要的度量标准，其具体形式涵盖了 Manhattan 距离、Euclidean 距离和 Chebyshev 距离等，适用于不同几何特性的数据分布分析。

2.4 K-means 聚类

K-means 算法是聚类中一种十分经典的算法，广泛应用于机器学习等领域 [8]。在具体的算法实现层面，典型的迭代算法通过不断优化类分配方案来确定最终的聚类结果。该算法首先根据给定的类分配方案计算每个类的均值向量集合 $g_1, \dots, g_K$ ；随后，将每个对象分配给距离其均值向量最近的类，形成新的划分。这两个步骤——即计算类中心和重新分配样本——不断循环迭代，直至评价函数值收敛不再发生变化。从操作细节来看，算法首先进行初始化，随机选择 K 个种子点。在类的分配阶段，依据最近邻原则将数据点归类，即

$$\text{Cluster}(u_i) = \operatorname{argmin}(d(u_i, g_i))$$

最后，算法进入更新中心环节，通过计算当前类内所有样本的平均值来更新类中心

$$g_j = \frac{1}{n} \sum_{u_i \in j\text{-th cluster}} u_i$$

关于算法的收敛性，首先需要对聚类问题进行精确的数学描述。给定数据集 $u_1, \dots, u_N$ （其中 $u_n \in \mathbb{R}^D$ ）以及 K 个类别的均值向量 g_v ($v = 1, \dots, K$)，问题的核心目标是寻求一种数据点的分配方案，使得所有数据点与其所属类别的均值向量 g_v 之间的平均距离最小。为了对该目标进行形式化表达，引入二值指示变量 $r_{nv} \in 0, 1$ 。当 $r_{nv} = 1$ 时，表示数据点 u_n 被分配到第 v 个类；当 $r_{nv} = 0$ 时，则表示不属于该类。对于每一个数据点 u_n ，其对应的指示向量 $r_{n,\cdot}$ 具有唯一性，即 $(0, \dots, 0, 1, 0, \dots, 0)$ 的形式，保证每个数据点在划分中仅有一个元素为 1，其余皆为 0。

基于前述的形式化定义，聚类的优化目标被明确为最小化所有数据点到其所属类中心的平均平方距离，即损失函数

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{v=1}^K r_{nv} \|u_n - g_v\|^2$$

在该目标函数中，指示变量 r_{nv} （代表点的归属）和均值向量 g_v （代表类的中心）是相互关联、彼此对应的变量。为了求解这一优化问题，算法采用了坐标下降法（Coordinate Descent）的策略：在每次迭代中，交替固定其中一组变量而优化另一组变量。具体而言，即通过在更新类中心和重新分配样本点之间循环迭代，逐步逼近最优解，直至损失函数 J 的值不再发生变化，从而实现算法的收敛。

在算法的收敛过程中，采用坐标下降法确保代价函数 J 能够逐步下降直至收敛。具体步骤包含两个交替进行的阶段：首先，固定类中心 g_v 来优化指示变量 r_{nv} 。这一步实质上是将每个点分配给距离其最近的类，即仅当 v 为使 $\|u_n - g_k\|^2$ 最小的索引时， r_{nv} 取值为 1，否则为 0。随后，固定 r_{nv} 来优化类中心 g_v 。通过求解代价函数关于 g_v 的偏导数 $\frac{\partial J}{\partial g_v}$ 并令其为 0，可以得到类中心的更新公式： g_v 等于该类内所有数据点的均值（即 $\frac{\sum_n r_{nv} u_n}{\sum_n r_{nv}}$ ）。通过不断循环上述“分配”与“更新”的过程，算法虽然能够保证收敛，但需指出的是，这种方法通常只能保证找到局部最优解，而不能保证找到全局最优解。

综合上述分析，该聚类算法展现出了一系列明确的特性。首先，在模型层面，它基于向量空间模型构建，其核心策略是最小化类内对象的欧氏距

离。算法实现上采用迭代式的坐标下降法，属于典型的硬聚类与非层次聚类方法。在适用性方面，该算法对于数据呈现为几个紧凑且相互分离的云状分布时效果显著，并且即便对于类大小差异较大或边界非凸的情况也能保持一定的有效性。然而，该算法也存在明显的局限性，即对噪声数据和离群点极度敏感，这些异常值往往会显著干扰聚类中心的计算，从而影响最终的聚类质量。

2.5 聚类数 K

在聚类分析的实践中，确定最佳的聚类数量 K 是一个至关重要且充满挑战的问题 [9]。通常，首选的方法是“问题驱动”，即依据具体的应用场景、业务逻辑或先验知识来设定一个合理的 K 值。这种方法直接利用了领域知识，往往在工程实践中最为高效和直观。

若试图脱离人工干预，采用纯“数据驱动”的方法来自动确定 K 值，则需要满足特定的数据条件。具体而言，数据本身不能过于稀疏，且在度量的特征维度中不应包含明显的噪声，否则统计规律极易被干扰。当 K 值未事先给定时，一个常用的评估思路是考察类内不相似度 W_k （即聚类误差平方和 SSE）。一般规律是，随着 K 值的增加，每个簇的半径会变小， W_k 值通常会呈现单调下降的趋势。单纯追求 W_k 的最小化会导致 K 等于样本数，因此需要更复杂的指标。

为了在偏差与方差之间取得平衡，更精确地定位最佳 K 值，可以使用 Gap Statistic（间隙统计量）这一指标 [10]。其核心思想是将实际数据的聚类效果与一个参考分布（通常为均匀分布）下的聚类效果进行比较。Gap Statistic 的定义为：

$$Gap(k) = E_n(\log W_k^*) - \log W_k$$

其中， $E_n(\log W_k^*)$ 表示在参考分布（通常为均匀分布）下生成的类内不相似度的对数值的期望。由于该理论期望值往往难以直接通过解析式计算，实践中通常采用 Monte Carlo 方法，通过在参考分布下进行多次模拟实验并取平均值来近似代替；而 $\log W_k$ 则是基于真实观测数据计算得到的类内不相似度的对数。类内不相似度 W_k 具体计算为所有类别中点到其类中心的欧氏距离平方之和：

$$W_k = \sum_{k=1}^K \sum_{u_i \in k\text{-th cluster}} \|u_i - g_k\|^2$$

通过比较实际数据的 W_k 与均匀分布数据下的期望值，我们可以判断当前的聚类结构是否显著优于随机分布。通常我们会选择首个使得 $\text{Gap}(k)$ 达到最大值（或在一定范围内满足判定条件）的 K 作为最佳聚类数。

然而，理论上的最佳统计量并不总是意味着最佳的下游任务表现。以经典的 Iris 数据集为例，通过计算可以发现，在不同聚类数下，真实数据与均匀分布数据的类内不相似度差值在 $K = 4$ 时首次达到最大，根据 Gap Statistic 准则， $K = 4$ 应被视为最佳聚类数。但在进一步的验证中发现， $K = 3$ 时的聚类准确率达到了 0.887，反而高于 $K = 4$ 时的 0.853。这一现象深刻说明，聚类效果的评估不应仅取决于几何结构上的类内不相似度（紧密度），还需综合考虑数据本身的物理分布特性以及后续分类或应用的实际需求。




图 1: 真实数据与均匀数据下的类内不相似度

2.6 K-medoids 聚类

K-medoids 聚类算法是对传统 K-means 的一种重要变体。其核心区别在于，K-medoids 不再使用类的均值 (Mean) 作为聚类中心，而是选择类中最靠近中心的对象 (Medoid) 作为参考点。其基本策略是：从 n 个对象中随机选取 k 个作为初始代表对象，在迭代过程中，将其他对象分配给距离最近

的类中心，并计算使代价函数（即类内对象与类中心的平均不相似度）最小的类中心，直至不再发生变化。为了具体实现这一优化，PAM (Partitioning Around Medoids) 算法被提出，它在迭代阶段尝试用非中心对象随机替换当前类中心，若替换能降低代价（提高类质量）则保留该替换。这种方法具有显著的优点：相比于 K-means，K-medoids 对噪声和离群点具有更强的鲁棒性；且在理论上，若能遍历所有情况，可保证得到最优划分。然而，其缺点也较为明显，即每次迭代计算中心的时间复杂度为 $O(n^2)$ ，导致其运行速度较慢，难以直接应用于大规模数据集。为了解决大数据集的效率问题，CLARA (Clustering LARge Applications) 算法应运而生。CLARA 的基本策略是针对大样本采用抽样的方法，每次只随机选取一小部分样本进行 PAM 聚类，随后将剩余样本按距离归类。通过多次重复这一抽样与聚类过程，CLARA 最终选取误差最小（即中心点代换代价最小）的结果作为最终输出，从而在保证效果的同时显著提升了处理大规模数据的能力 [8]。

3 技术细节

3.1 聚类标签的对齐

在评估 K-means 聚类算法的实际性能时，我们面临的一个核心挑战在于聚类标签的任意性与无序性。作为一种典型的无监督学习算法，K-means 的输出结果仅仅是将数据划分为若干个互不重叠的子集，其分配的簇标签（如 0, 1, 2,...）通常是随机产生的索引值，并不具备任何语义含义，更不直接对应数据集中预设的真实类别标签。例如，算法输出的“簇 0”可能完全对应真实样本中的类别“9”，甚至可能在不同的运行次序中发生改变。因此，若直接将预测标签与真实标签进行一一对应的数值比较，将会导致错误的计算结果，使得直接计算准确率变得毫无意义。

为了克服这一“标签对齐”的难题并准确量化聚类效果，通常采用多数投票重映射 (Majority Voting Remapping) 的解决方案。该方法的核心逻辑是利用真实标签作为监督信号，通过统计规律建立一个从预测簇标签到真实类别标签的最优映射关系。其具体实施策略如下：对于算法生成的每一个预测簇，遍历其内部所有的样本，统计这些样本所属真实类别的频次分布，并找出出现次数最多的类别（即众数）。随后，将该簇内的所有样本统一重新标记为这个众数类别。通过这种方式，我们可以将无序的预测标签强制映射到有序的真实标签空间，从而消除标签不一致带来的干扰，实现评估指标

的有效计算。

3.2 图像旋转

针对手写数字图像中普遍存在的书写倾斜问题，直接进行聚类分析会因特征空间的不对齐而引入较大的误差。因此，图像旋转预处理的核心目标是利用主成分分析（PCA）提取图像中数字的主要几何延伸方向，并通过刚体变换将图像旋转至与 Y 轴垂直对齐，从而实现数据的标准化 [11]。具体实现步骤及公式如下：

1. 提取图像中所有非零像素（即前景像素）的坐标集合；
2. 计算这些像素点的几何质心 μ ，并将所有点的坐标平移至以该质心为原点的坐标系中；
3. 对中心化后的数据进行 PCA 分析，提取第一主成分向量 $v_1 = (v_x, v_y)$ ，该向量代表了图像的主要延伸方向；
4. 计算第一主成分向量与 Y 轴之间的夹角 θ ，利用点积确定夹角大小，并通过叉积判断旋转方向，最终计算公式为

$$\theta = -\text{sign}(v_y) \cdot \arccos(v_x)$$

5. 根据计算出的角度 θ 构建标准的二维旋转矩阵

$$R = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$$

6. 将图像像素坐标映射到以质心为中心的坐标系中，应用该旋转矩阵进行变换，然后再反向映射回原坐标系，变换公式为

$$x_{rot} = R \cdot (x - \mu) + \mu$$

在此过程中，采用双线性插值方法对旋转后的坐标进行采样，以填充新图像的像素值，从而有效减少旋转带来的图像失真和锯齿。




图 2: 原图像




图 3: 旋转后的图像

配图直观地展示了原图像与经过上述算法旋转并标准化后的图像效果对比，可以明显观察到数字的主轴已被修正至垂直方向，且图像细节得到了良好保持。

3.3 HOG

HOG (Histogram of Oriented Gradients, 方向梯度直方图) 特征是一种在计算机视觉领域广泛使用的特征描述符，其本质是通过计算和统计图像局部区域的梯度方向直方图来构建的。该特征的核心物理假设在于：在一个局部单元格内，物体的外观和形状能够被梯度或边缘方向的分布有效地描述，而无需关心梯度或边缘的具体强度或位置 [12]。

其具体构成流程通常包含以下几个关键步骤：

1. 将图像划分为若干小的、连通的区域，称为“单元格”；接着，计算图像中每个像素点的梯度幅值和方向（通常通过水平和垂直方向的 Sobel 算子滤波获得）；
2. 将这些像素的梯度方向按照权重（如梯度幅值）累加到对应单元格的直方图中（通常将 0° - 180° 或 0° - 360° 划分为 9 个区间）；
3. 为了进一步抑制光照和阴影带来的影响，算法会将相邻的若干单元格组合成一个“块”，并对块内的直方图进行归一化处理（如 L^2 范数归一化）；

4. 将所有块的归一化直方图向量串联起来，形成最终的高维特征向量。

就其特性而言，HOG 特征具有极强的局部形状描述能力，尤其擅长描述行人的轮廓等刚性物体。由于采用了归一化处理，它对光照变化和背景噪声具有很好的不变性。然而，该方法也伴随着特征维度较高的问题（例如对于 64×128 的图像，其特征维度可达 3780 维），这会增加计算和存储的负担。此外，由于它侧重于局部统计特征的叠加，缺乏对全局空间结构的显式建模，因此在识别对整体形状依赖较强的物体时可能存在局限 [13]。

4 实验结果

4.1 直接采用 K-means 聚类

我们首先不考虑对原始数据进行任何预处理，直接对完整的 MNIST 数据集进行 K-means 聚类（关于聚类数的选取，根据问题驱动的原则，由于共有 10 个阿拉伯数字，此处选取 $K = 10$ ）。将标签对齐后，与数据集原有的标签数据比对，我们得到了 0.585 的准确率。




图 4: 直接采用 K-means 聚类时的混淆矩阵

可见，尽管 K-means 算法一般在 iris 数据集等基础场景中表现良好，

但将其直接应用于 MNIST 这种具有样本量更大、数据维数更高以及特征相关性更复杂特性的手写数字数据集时，其表现出的效果不够理想。进一步的实践表明，即便在应用 K-means 之前引入 PCA（主成分分析）等降维技术对数据进行预处理，模型的聚类准确率指标仍然只能维持在 60% 左右，难以满足高精度的应用需求。




图 5: 直接采用 K-means 聚类时各数字族的样本

通过观察各个族中的样本，可以发现本场景中的两个主要问题：一是图像中数字的旋转会显著干扰 K-means 基于欧氏距离的聚类结果；二是数字“5”和“9”的特征区分度不足，导致它们未能被有效地单独提取为一类。针对上述局限性，未来的改进方向应着重于：消除图像旋转带来的影响，采用更专业的针对图像识别的特征提取方法，以及适当增加聚类数量以细化数据结构。




图 6: 引入 PCA 旋转方法后的混淆矩阵

4.2 引入 PCA 旋转方法

为消除图像旋转带来的影响，利用 3.2 节提到的 PCA 旋转方法对原始数据进行预处理，随后再进行 K-means 聚类，这次我们得到了 0.681 的准确率。相比上一小节的直接 K-means 方法，准确率得到了显著提升，但仍不足以令人满意。

具体观察混淆矩阵，我们注意到误判主要还是集中在数字“5”、“7”、“9”，说明这些数字的特征仍然没有被很好地提取出来。

4.3 提取 HOG 特征

为更好地分辨不同数字的形状特征，我们对原始图像灰度数据进行 HOG 特征提取处理，再对提取出来的 HOG 特征数据进行 K-means 聚类。此时，准确率达到了 0.726，相比前一小节有了一定的进步。

从混淆矩阵上看，数字“5”、“7”、“9”的误判情况得到了一定程度的缓解，但仍是“重灾区”。这提醒我们，由于手写体数字的固有特性，以上几个数字内禀的族内差异可能并不弱于族间差异。因此，接下来或许需要增加聚类数以保证各族在欧氏空间中的大小的平衡。




图 7: 提取 HOG 特征后的混淆矩阵




图 8: 提取 HOG 特征并增加聚类数后的混淆矩阵

4.4 增加聚类数 K

我们选取聚类数 $K = 100$ ，重新对原始数据进行 K-means 聚类。将标签对齐后，我们得到了 0.877 的准确率，实现了明显的效果提升。

更进一步，我们将 HOG 特征提取方法也结合进来。先对原始图像进行 HOG 特征提取处理，再对特征数据进行 $K = 100$ 的 K-means 聚类，最终得到了 0.921 的准确率。

从混淆矩阵和各族样本来看，误判的情况得到了极大的减少，我们认为这样的聚类效果是令人满意的。

实际上，通过继续增大聚类数 K ，还可以进一步提高准确率。然而在实际意义下，这种做法存在边际效益递减的问题，原因详见下一节。




图 9: 提取 HOG 特征并增加聚类数后各数字族的样本

5 总结

通过陆续引入各种技术，我们令 K-means 聚类方法在 MNIST 手写数字识别问题上的表现得到了逐步的提升，准确率由 0.585 一步步提升至 0.921。

横向对比其他研究在 MNIST 数据集上的表现，[1] 中的核方法最高准确率为 89.2%，而 [2] 中的混合高斯模型最高仅达到 73.6% 的准确率，我们的方法效果均强于二者。

实践意义下，我们的“HOG 特征提取 + 增加聚类数”的方法能够应用于数据的半自动标注。之所以是半自动，是因为 $K = 100$ 个类无法自动地与 10 个阿拉伯数字完成一一对应，故仍需要人为进行少量标注。而随着 K 进一步增大（如 1000, 10000），人工标注的成本则会提高，而准确率并不会会有突飞猛进的提升。这便是实践中不考虑过大的聚类数 K 的原因。

6 参考文献

- [1] Zhang, Rong, and Alexander I. Rudnicky. A large scale clustering scheme for kernel k-means. 2002 International conference on pattern recognition. Vol. 4. IEEE, 2002.
- [2] Liu, Jialu, Deng Cai, and Xiaofei He. Gaussian mixture model with local consistency. Proceedings of the AAAI conference on artificial intelligence. Vol. 24. No. 1. 2010.
- [3] 陈新庚, 等. 一种改进的 K-means 聚类算法研究 [J]. 计算机工程与应用, 2003.
- [4] Xie, Junyuan, Ross Girshick, and Ali Farhadi. Unsupervised deep embedding for clustering analysis. International conference on machine learning. PMLR, 2016.
- [5] Ji, Xu, Joao F. Henriques, and Andrea Vedaldi. Invariant information clustering for unsupervised image classification and segmentation. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019.

- [6] 甘井中, 杨秀兰, 吕洁, 等. 人工智能中无监督学习算法综述 [J]. 海峡科技与产业, 2019, (01): 134-135.
- [7] 孙吉贵, 刘杰, 赵连宇. 聚类算法研究 [J]. 软件学报, 2008, (01): 48-61.
- [8] 杨俊闯, 赵超. K-Means 聚类算法研究综述 [J]. 计算机工程与应用, 2019, 55(23): 7-14+63.
- [9] 周世兵. 聚类分析中的最佳聚类数确定方法研究及应用 [D]. 江南大学, 2011.
- [10] Tibshirani, R., Walther, G., & Hastie, T. (2001). Estimating the number of clusters in a data set via the gap statistic. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 63.
- [11] 王欢. 手写数字识别中的图像平移旋转及特征提取问题研究 [D]. 兰州大学, 2018.
- [12] Dalal N, Triggs B. Histograms of oriented gradients for human detection. *Computer Vision and Pattern Recognition*, 2005. CVPR 2005.
- [13] 徐渊, 许晓亮, 李才年, 等. 结合 SVM 分类器与 HOG 特征提取的行人检测 [J]. 计算机工程, 2016, 42(01): 56-60+65.